

1. Vedieť určiť vlastnosti atributov - priemery, početnosti, kvantily atď.

• Racionálny = [165, 170, 175, 180, 185, 190, 195, 200]

1. Среднее значение: $\bar{x} = \frac{165+170+175+\dots+200}{8} = 196,25$

2. Медиана: $M = \frac{180+185}{2} = 182,5$ (разложив числа в порядке возрастания)

3. Мода: нет повторяющихся значений, нет моды

4. Стандартное отклонение: $\sigma = \sqrt{\frac{(x_1 - \bar{x})^2 + \dots + (x_n - \bar{x})^2}{n}} = \sqrt{\frac{(165-196,25)^2 + \dots + (200-196,25)^2}{8}}$

5. Квантили: $Q_1 = \frac{170+175}{2}$ $Q_2 = M = 182,5$ $Q_3 = \frac{195+190}{2}$

• Категориальности: Nominálny (množko početností, frekvencie distr)


Ordinálny (Nomin + median / percentily)

2. Načrtnúť z daných hodnôt atribútu jednoduché grafy ako histogram či boxplot, vrátane podmienených verzií

• Boxplot: 3, 15, 4, 18, 5, 10, 9, 12, 3, 5



1. в порядке возрастания: 3, 3, 4, 5, 5, 9, 10, 12, 15, 18


2. Min = 3, Max = 18, Median = $\frac{5+9}{2} = 7$, $Q_1 = 4$, $Q_3 = 12$




• Histogram: 1, 3, 27, 32, 5, 63, 26, 25, 18, 16, 4, 45, 29, 19, 22, 51, 58, 9, 42, 6

Bucket	#
0-9	6
10-19	3
20-29	5
30-39	1
40-49	2
50-59	2
60-69	1






- DICE - vytvorenie pohľadu pre vyber hodnôt viacerých




DICE on $C = C_1, C_2$
 $L = L_1, L_2$
 $I = I_1, I_2$

- SLICE - vytvorenie pohľadu na kocku pre konkrétnu hodnotu




SLICE on Q

- DRILL-DOWN - navigácia k detailnejším dátam zoskupením v hierarchii konceptov / prídanie dimenzií



DRILL DOWN on Time

- ROLL-UP - agregovanie hodnôt v rámci databovej kocky vystupaním menej v hierarchii konceptov



ROLL UP on Location

- DRILL-ACROSS - prechod na inú hierar. definovanú nad rovnakou dimenziou (deň-mesiac-kvartál-rok → deň-tyždeň-rok)

- DRILL-THROUGH - prechod na úrovni záznamov v tabuľke - čítanie dát v tabuľke faktor.

- ROTATION (PIVOT) - vizualizačná operácia, ktorá rotuje (zamení) osi pre zmenu aktuálneho pohľadu na tabuľku

4. normalizácia - vedieť realizovať rôzne typy normalizácie pre
žadany atribút, určiť hodnoty normalizovaného atribútu.

- Min-max normalizácia ($\langle -1, 1 \rangle$ alebo $\langle 0, 1 \rangle$)

z intervalu $\langle \min A, \max A \rangle$ do $\langle \text{new-min } A, \text{new-max } A \rangle$

$$v' = \frac{v - \min A}{\max A - \min A} \cdot (\text{new-max } A - \text{new-min } A) + \text{new-min } A$$

príklad: $\{50, 62, 34, 8\} \rightarrow \langle -1, 1 \rangle$
min=8, max=62

$$v'_1 = \frac{50 - 8}{62 - 8} \cdot (1 - (-1)) + (-1) = 0.5$$

- Normalizácia na nulový stred (standardizácia, z-score n)

$$v' = \frac{v - \bar{x}_A}{S_A}$$

$\bar{x}_A$ - početne guaveme

S_A - štandardná odchyľka

$$S_A = \sqrt{\frac{\sum (x_i - \bar{x}_A)^2}{N}}$$

príklad: $\{50, 62, 34, 8\}$

$$\bar{x}_A = \frac{50 + 62 + 34 + 8}{4} = 38.5$$

$$S_A = \sqrt{\frac{(50 - 38.5)^2 + (62 - 38.5)^2 + (34 - 38.5)^2 + (8 - 38.5)^2}{4}} = \dots$$

$$v' = \frac{50 - \bar{x}_A}{S_A} = \dots$$


- Normalizácia decimálnym škalovaním

$$v' = \frac{v}{10^j} \quad , \quad j = \text{najmenšie celé číslo, také že } \max(|v'|) < 1$$

re?

⑤ Diskretizácia - vedieť určiť hodnoty diskretizovaného atribútu (ekvifrekvenčné / ekvidistančné)


• Ekvidistančná (rovinný шаг)



шаг=3

разбиваем на промежутки с определенным шагом, заносим значения, попадающие в промежутки

• Эквифреквенčná (каждый интервал содержит +/- одинаковое число наблюдений)



⑥ Vedieť určiť model lineárnej regresie $\neq$ dát, vedieť určiť hodnotu pre nový príklad, vedieť vyhodnotiť rozdiel medzi predikciou a skutočnou hodnotou.

X	POČET ROKOV V PRAXE	3	8	9	13	3	6	11	21	1	16
Y	PRÍJEM	30	57	64	72	36	43	59	90	20	83

$$\bar{X} = 9.1$$

$$\bar{Y} = 55.4$$

$$y = a + \beta x$$

$$a = \bar{y} - \beta \bar{x}$$

$$\beta = \frac{\sum_{i=1}^n (x_i - \bar{x}) \cdot (y_i - \bar{y})}{\sum_{i=1}^n (x_i - \bar{x})^2}$$

$$\beta = \frac{(3-9.1)(30-55.4) + (8-9.1)(57-55.4) + \dots + (16-9.1)(83-55.4)}{(3-9.1)^2 + (8-9.1)^2 + \dots + (16-9.1)^2} = 3.5$$

$$a = 55.4 - 3.5 \cdot 9.1 = 23.6$$

$$Y = 23.6 + 3.5X$$

↳ môžeme používať na predikovanie hodnôt príjmy.

napr. počet rokov v praxe = 10 : $Y = 23.6 + 3.5 \cdot 10 = 58.600$

7) Vediet' zostavit' jednoduchý rozhodovací strom & dát (výber podľa poradia atribútu by bol daný), vediet' určiť klasifikáciu pomocou tohto stromu pre nový príklad

?

III

$$H(S) = - \sum_{j=1}^2 \frac{n_j}{n_1+n_2} \log_2 \frac{n_j}{n_1+n_2} \quad H(S, A) = \sum_{j=1}^2 \frac{n_j}{n_1+n_2} \cdot H(S_j)$$

$$I(A) = H(S) - H(S, A)$$

ID3

Temp	Влажность	Ветер	Ураган
25	70	слаб	+
20	65	сильн	-
22	90	сильн	+
18	75	слаб	-
28	80	сильн	+

poradie atr: T → B₁ → B

если температура $\neq 18^\circ\text{C}$,
влажность = 70 → ураган



8) Určit' zaradenie príkladu do triedy podľa Naive Bayes

$$p(a/x) = \frac{p(a) p(x/a)}{p(x)} \quad \text{Bayesovo pravidlo}$$

príklad: Outlook=sun, Temp=cool,
Humid=high, Wind=strong.

$$p(\text{yes}) = \frac{9}{14} \quad p(\text{no}) = \frac{5}{14}$$

$$p(\text{wind=strong} + \text{yes}) = \frac{3}{9}$$

$$p(\text{wind=strong} + \text{no}) = \frac{2}{5}$$

$$p(\text{outlook=sun} + \text{yes}) =$$

Day	Outlook	Temp	Hum	Wind	Play
1	S	H	H	W	-
2	S	H	H	S	+
3	O	H	H	W	+
4	R	M	H	W	+
5	R	C	N	W	+
6	R	C	N	S	+
7	O	C	N	S	+
8	S	M	H	M	-
9	S	C	N	W	+
10	R	M	N	W	+
11	S	M	N	S	+
12	O	M	H	S	+
13	O	H	N	W	+
14	R	M	H	S	+

$y = \text{yes}, n = \text{no}$

$$p(y/X) = p(y) \cdot p(\text{sun} + y) \cdot p(\text{cool} + y) \cdot p(\text{high} + y) \cdot p(\text{strong} + y)$$

$$p(n/X) = p(y) \cdot p(\text{sun} + \text{no}) \cdot p(\text{cool} + \text{no}) \cdot p(\text{high} + \text{no}) \cdot p(\text{strong} + \text{no})$$

$$p(y/X) = 0.005 < p(n/X) = 0.02 \leftarrow \text{vybrana trieda "no"}$$

⑨ KNN - určiť zaradenie príkladov do tried pomocou KNN podľa zadania (data, k, typ použitej vzdialenosti)

Euklidovska

$$E(x, y) = \sqrt{\sum_{i=1}^d (x_i - y_i)^2}$$

Kosinusova

$$C(x, y) = \frac{\sum_{i=1}^d x_i y_i}{\sqrt{\sum_{i=1}^d x_i^2} \sqrt{\sum_{i=1}^d y_i^2}}$$

Manhattan

$$\text{dist}(x, y) = \sum_{i=1}^d |x_i - y_i|$$

⑩ určiť zaradenie príkladov do zhlukov pre jednoduchý KMeans model

$X = \{x_1, \dots, x_n\}$ - objekty


$Y = \{y_1, \dots, y_k\}$ - k zhlukov

$$y_j = \frac{\sum_{x_i \in Y_j} x_i}{|Y_j|} \quad \text{- výpočet polohy centroidu}$$

Chybová funkcia = suma odchýlok objektov od stredov ich zhlukov

Algoritmus:

1. k náhodne vybraných centier
2. Priradenie obj najbližšiemu zhluku
3. Výpočet nových centier zhlukov
4. Ukončovacia podmienka



$$d = \sqrt{(x_2 - x_1)^2 + (y_2 - y_1)^2}$$

$$3. (x', y') = \left(\frac{x_1 + x_2 + x_3}{3}, \frac{y_1 + y_2 + y_3}{3} \right)$$

// eam & kvadraty 3 yuarems



// сумаме расстояние от него
приспери к каждому центру,
к какому ближе то маюм и отнесем.

- 11) Confusion Matrix - vedieť zostaviť CM z výsledkov testovania, čo žadané alebo vypočítanej CM vedieť určiť metriky, vedieť ich určiť pre jednoduchú binárnu CM, ale aj väčšiu viaceriednu, rozumieť spriemerovaniu a vedieť ho aplikovať (mikro alebo makro)

	z danej triedy	nie je z dt.
Klasifikátor (z danej)	TP true positive	FP false positive
Klasifikátor (nie je z dt.)	FN false negative	TN true negative

SPRIEMEROVANIE

MIKROSPRIEMEROVANIE - spočítame hodnoty v tabuľkách dokopy do jednej spoločnej tabuľky a potom použijeme vzorec pre zvolenú mierku

$$\frac{TP+TN}{TP+FP+FN+TN} \rightarrow \text{accuracy}$$

MAKROSPRIEMEROVANIE - najprv spočítame zvolenú mierku pre každú tabuľku triedy zvlášť a potom urobíme ich priemer.

$$\frac{a_1 + a_2 + a_3}{3} \rightarrow \text{accuracy}$$

$$\bullet \text{ accuracy} = \frac{TP+TN}{\text{sumet všetkých}}$$

úspešnosť klasif.

$$\bullet \text{ chyta klasifikácie} = \frac{FN+FP}{\text{sumet všetkých}}$$

presnosť

$$\bullet \text{ precision} = \frac{TP}{TP+FP}$$

$$\bullet \text{ recall} = \frac{TP}{TP+FN}$$

navratnosť

$$\bullet F1 \text{ skóre} = \frac{2 * \text{precision} * \text{recall}}{\text{precision} + \text{recall}}$$

viaceriedna

PREDIK	Frieda	skutočná		
		A	B	C
A	A	2	2	0
	B	1	2	0
	C	0	0	3

$$A \text{ presnosť} = \frac{2}{2+2+0}$$

$$A \text{ navratnosť} = \frac{2}{2+1+0}$$

- 12) vedieť vyhodnotiť podporu a spoľahlivosť asocičných pravidiel

ID	kupene položky
2000	A, B, C
1000	A, C
4000	A, D
5000	B, E, F

min podpora

min spoľahliv.

50%

frekvencované množiny položiek	podpora
{A}	75%
{B}	50%
{C}	50%
{A, C}	50%

$$\text{Podpora} = P(X \cup Y)$$

$$\text{Spoľahlivosť} = P(Y/X) = \frac{P(X \cup Y)}{P(X)}$$

$$\text{Lift confidence: } (X \Rightarrow Y) = \frac{P(X \cup Y)}{P(X) \cdot P(Y)}$$

pravidlo $A \Rightarrow C$

$$\text{podpora} = \text{podpora}(\{A, C\}) = \frac{2}{4} = 50\%$$

$$\text{spoľahlivosť} = \text{podpora}(\{A, C\}) / \text{podpora}(\{A\}) = \frac{2}{4} = 50\%$$

pravidlo $C \Rightarrow A$

$$\text{podpora} = \text{podpora}(\{C, A\}) = \frac{2}{4} = 50\%$$

$$\text{spoľahlivosť} = \text{podpora}(\{C, A\}) / \text{podpora}(\{C\}) = \frac{2}{2} = 100\%$$

- 13) Vedit' zostavit' jednoduchy linearny program zo rovnice zadania (premenne, obmedzenia, kriterialna fcia)

$$\begin{aligned}
 & \text{KF: } \max(143x + 60y) \\
 & \left. \begin{aligned} 120x + 210y &\leq 15000 \\ 110x + 30y &\leq 4000 \\ x + y &\leq 75 \\ x &\geq 0 \\ y &\geq 0 \end{aligned} \right\} \begin{array}{l} \text{obmedzenia} \\ \text{default} \\ \text{obmedzenia} \\ \text{o nepozornosti} \\ \text{vstupcu} \end{array}
 \end{aligned}$$

KF: kriterialna fcia

$x_1, x_2, \dots, x_n$ - reálne premenne

KF = lineárna kombinácia premenných + fakt o úlohe optimalizácie (min/max)

ПРИМЕР

есмо 2 буда продукци. Для продукто I буда купю 3 заца работ, II - 2 заца. В кедено 120 работ работует времени. Каждый единица Iro продукта приносит 5\$ прибыли, Y - 4\$. Цена - максимизирует прибыль.

X - I буд Y - II буд

$$\begin{aligned}
 & \text{KF: } \max(5x + 4y) \\
 & 3x + 2y \leq 120 \\
 & x \geq 0 \quad y \geq 0
 \end{aligned}$$

- 14) Vedit' zostavit' rozhodovaciu tabuľku zo zadania (vid' príklad z prechodom križovatky)

PRECHOD KRIŽOVATKY	Kombinácie			
	1	2	3	4
Riadená križovatka	A	A	N	N
Svieti zelená	A	N	-	-
Účelne v smere premávky	-	-	A	N
Prichádzajúce vozidlá v dostatočnej vzdialenosti	-	-	-	A
PREJST'	X	-	X	X
POČKAŤ	-	X	-	-

- 15) Určit' TF-IDF hodnoty dokument-term matice zo zadania výskytu slov v dokumentoch

Документ 1: "Маминко, отличное решение"

Документ 2: "Летние маминко впечатления..."

Документ 3: "Маминко и летние впечатления"

$$x_{ij} = t f_{i,j} \cdot \log\left(\frac{N}{df_i}\right)$$

$$TF(t, d) = \frac{\text{кратко терм в документе}}{\text{общая кратко терм в документе}}$$

$$TF(\text{"маминко"}, \text{Документ 1}) = \frac{1}{3}$$

$$IDF(\text{"маминко"}, D) = \log\left(\frac{3}{3}\right) = -0.1249$$

$$IDF(t, D) = \log\left(\frac{\text{общая кратко терм в документе}}{\text{кратко терм, содержа терм t}}$$

$$x_{ij} = \frac{1}{3} \cdot (-0.1249) = -0.0416$$

16) Vedieť správne určiť aké porovnania je potrebné urobiť pre AHP (Analytic Hierarchy Process) vzhľadom k zadaniu + rozumne určiť hodnoty porovnania podľa zadania

(V)

1. Urpečeniu faktorov u kriterijov faktorov

2. Komentaem faktorov vinnocentno dpyt dpyt u kriterijov

①

	A	B	C	D
A	1	5	4	7
B	$\frac{1}{5}$	1	$\frac{1}{2}$	3
C	$\frac{1}{4}$	$\frac{1}{2}$	1	3
D	$\frac{1}{7}$	$\frac{1}{3}$	$\frac{1}{3}$	1
Sum	1.59	8.33	5.83	14

B-A; B-x Value, A-5x Value $\frac{5x}{x} = 5$
A faktor B.

% sum

	A	B	C	D	Criteria weights
A	$\frac{1}{1.59}$	$\frac{5}{8.33}$	$\frac{4}{7}$	$\frac{7}{14}$	$\frac{A+B+C+D}{4} = 0.6038$
B	$\frac{0.2}{1.59}$	$\frac{1}{8.33}$	$\frac{0.5}{7}$	$\frac{3}{14}$	- - = 0.1365
C	$\frac{0.25}{1.59}$	$\frac{2}{8.33}$	$\frac{1}{7}$	$\frac{3}{14}$	- - = 0.1958
D	$\frac{0.14}{1.59}$	$\frac{0.33}{8.33}$	$\frac{0.33}{7}$	$\frac{1}{14}$	- - = 0.0646

① * ② (Criteria weights)

	A	B	C	D	Weighted Sum Value	Criteria Weighted	
A	$1 * 0.6038$				2.5217	0.6038	I
B	$0.2 * 0.6038$				0.5490	0.1365	II
C	$0.25 * 0.6038$	$0.1365 * 0.1958$			0.8136	0.1958	III
D	$0.14 * 0.6038$	$0.33 * 0.0646$	$0.33 * 0.1958$		0.2616	0.0646	IV

$$\lambda_{max} = \frac{I + II + III + IV}{4} = 4.1007$$

n	1	2	3	4	5	6
RI	0	0	0.58	0.9	1.12	1.24

$$CI = \frac{\lambda_{max} - n}{n - 1} = \frac{4.1007 - 4}{4 - 1} = 0.03358$$

consistency index

$$CR = \frac{CI}{RI \text{ (random index)}} = \frac{0.03358}{0.90} = 0.037311 < 0.10$$

consistency ratio